

Métodos MCMC: Implementação, Diagnóstico e Aplicações Práticas

Ana Margarida Costa, Elisa Fornelos,
João Rocha e Rita Mota

Objetivos do estudo

01

Descrever o funcionamento e fundamentos dos métodos MCMC

02

Apresentar técnicas de diagnóstico e monitorização da convergência

03


Implementar e analisar o Metropolis–Hastings em R

04

Discutir resultados e possíveis melhorias

Conceitos-chave

- Cadeias de Markov: propriedade de transição e equilíbrio detalhado
- Teorema Ergódico: convergência das médias amostrais
- Eficiência depende da escolha da proposta $q(y \mid x)$



Algoritmo Metropolis– Hastings

1º passo

Gerar proposta:

- $y \sim q(y \mid x_t)$

2º passo

Calcular a probabilidade de aceitação:

- $\alpha = \min(1, [\pi(y) q(x_t \mid y)] / [\pi(x_t) q(y \mid x_t)])$

3º passo

Aceitar ou rejeitar y :

- Gerar $u \sim U(0,1)$
- Se $u < \alpha$, aceitar y e definir $x_{t+1} = y$
- Caso contrário, rejeitar y e definir $x_{t+1} = x_t$

Amostragem de Gibbs

Duas etapas

Escolher um valor inicial:

- $X_0 = x_0$

Para $t = 1, 2, \dots$ fazer:

- Gerar Y_t a partir de $f_{y|x}(\cdot | X_{t-1})$
- Gerar X_t a partir de $f_{x|y}(\cdot | Y_t)$

Multietapas

Dado $x(t) = (x_1(t), \dots, x_p(t))$

Para $i = 1, \dots, p$ fazer:

- Gerar $X_i(t+1) \sim f_i(x_i | x_1(t+1), \dots, x_{i-1}(t+1), x_{i+1}(t), \dots, x_p(t))$

Hamiltonian Monte Carlo (HMC)

- Introduce variável de momento e energia Hamiltoniana
- Usa integração numérica (leapfrog)
- Propõe saltos longos com alta aceitação

Vantagem:

reduz a autocorrelação → amostragem mais eficiente

No-U-Turn

- Extensão do HMC que adapta automaticamente o comprimento da trajetória, interrompendo-a quando deteta que o movimento está prestes a inverter a direção (no U-turn)
- Propõe saltos longos com alta aceitação

Vantagem:



Evita a calibração manual do
nº de passos de integração

→ amostragem mais eficiente




Aplicações:
Stan, PyMC

Diagnóstico da Convergência




- As flutuações aleatórias em torno de uma média constante sugerem uma boa mistura das cadeias e uma ausência de aprisionamento local, enquanto a variabilidade entre iterações evidencia uma exploração eficiente do espaço de estados.
- A convergência para o regime estacionário ocorre por volta das 2.000 iterações

Diagnóstico da Convergência




- A ACF apresenta uma descida acentuada nas primeiras defasagens (lags), aproximando-se de zero a partir de lag ≈ 10 . Isto indica que a dependência entre amostras consecutivas é reduzida, assegurando um tamanho efetivo da amostra (ESS) adequado.

Diagnóstico da Convergência




- A estatística de Gelman-Rubin avalia a consistência entre cadeias independentes. Com $R=1.01$, observa-se que as variâncias intra e intercadeias são praticamente idênticas, demonstrando convergência global.

Eficiência e taxa de aceitação




- A taxa de aceitação estabiliza em torno de 55%, um valor ligeiramente acima do intervalo ideal (20–40%). Isto indica que a proposta é algo conservadora — ou seja, os passos entre iterações são curtos e há poucas rejeições. Ainda assim, a estabilidade da taxa ao longo das iterações mostra que o processo de amostragem é fiável e que a cadeia atingiu o comportamento estacionário.

Visualização das Cadeias




- Usamos só uma das cadeias por ser mais simples e evitando assim duplicar amostras correlacionadas
- O histograma sobrepõe-se à densidade alvo (linha vermelha) de forma notavelmente próxima. As pequenas discrepâncias nas extremidades refletem a menor frequência de amostras em regiões de baixa densidade, comportamento típico de cadeias MH. O resultado comprova que o método recupera com elevada fidelidade a forma da densidade alvo.

Visualização das Cadeias



- A proximidade dos pontos à diagonal confirma que a distribuição empírica obtida pelas amostras MCMC coincide com a forma teórica esperada.

Visualização das Cadeias



- A média acumulada estabiliza após cerca de 2000 iterações, confirmando empiricamente o teorema ergódico.
- O valor final converge para $E[X] \approx -0.476$, consistente com as estimativas numéricas obtidas.
- A linha vermelha assinala o valor médio final, evidenciando estabilidade e ausência de tendência direcional.

Resultados Numéricos

$E[X] = -0.476$

$SD = 0.636$


ESS = 1641 ($\approx 16\%$ amostras independentes)

Boa estabilidade e baixa autocorrelação

Tempo total: < 2 segundos



EXTENSÕES E AVALIAÇÃO DE DESEMPENHO



- Avaliando-se a suavidade e cobertura da amostragem através da densidade kernel estimada a partir das amostras MCMC, observa-se excelente concordância, demonstrando que o método explora adequadamente todo o suporte da distribuição.

EXTENSÕES E AVALIAÇÃO DE DESEMPENHO

Comparando com a ***Amostragem de Gibbs***:

- O algoritmo de Metropolis–Hastings apresenta maior flexibilidade, pois permite usar propostas arbitrárias.
- A amostragem de Gibbs tende a convergir mais rapidamente em situações com condicionais analíticas conhecidas.

Para melhorar o desempenho:

- ***Adaptive Metropolis***– reduz a necessidade de calibração manual e melhora o ESS em distribuições multidimensionais.
- ***Delayed Rejection Adaptive Metropolis (DRAM)***– combina rejeições sucessivas com adaptação progressiva, aumentando a eficiência sem comprometer a ergodicidade da cadeia.

Limitações e Robustez Numérica

Desafios práticos

- Uma má escolha da proposta pode atrasar a convergência
- A dependência de amostras reduz a informação efetiva
- Em alta dimensionalidade, a convergência é mais difícil de avaliar e requer múltiplos diagnósticos

Resultados obtidos

- Mesmo com ESS moderado (1641), as estimativas mantêm-se consistentes e estáveis, o que demonstra a robustez do método e a validade do resultado



Perspetivas Futuras e Impacto Prático

Variantes baseadas em gradientes, como o ***Stochastic Gradient Langevin Dynamics (SGLD)*** e o ***Hamiltonian Variational Inference***, tem permitido aplicar MCMC a grandes volumes de dados, mantendo as propriedades assintóticas de correção estatística.

O impacto destes métodos é notório em áreas como:

- modelação de redes neuronais bayesianas,
- calibração de modelos climáticos e
- inferência em epidemiologia dinâmica.

Perspetivas Futuras e Impacto Prático

Neste momento: o MCMC assume-se não apenas como uma ferramenta de amostragem, mas como uma ponte entre a estatística teórica e a modelação de sistemas complexos do mundo real.

No futuro: espera-se que a combinação de MCMC com técnicas de machine learning — nomeadamente através do uso de redes neuronais para definir propostas inteligentes (*learned proposals*) — torne o processo mais adaptativo e eficiente.

APLICAÇÕES E CONCLUSÕES

- **Inferência Bayesiana:** estimação em modelos hierárquicos e regressões não lineares
- **Física Computacional:** simulação de sistemas moleculares e estudo de estados de equilíbrio
- ***Machine Learning*:** inferência em modelos probabilísticos complexos
- **Finanças e Epidemiologia:** previsão de volatilidade e modelação de contágio.

Conclusão

Em modelos unidimensionais simples, o MCMC, com uma análise cuidadosa da convergência, da eficiência amostral e aplicação prática em R comprovou que é capaz de produzir resultados precisos e interpretáveis.

Com a implementação devida, o MCMC continuará a constituir um dos pilares centrais da estatística computacional moderna e uma das ferramentas mais versáteis ao dispor do cientista de dados.

