

Métodos MCMC: Implementação, Diagnóstico e Aplicações Práticas

Ana Margarida Costa, Elisa Fornelos, João Rocha e Rita Mota
Faculdade de Ciências da Universidade do Porto
Mestrado em Estatística Computacional e Análise de Dados

Resumo—Os métodos de Cadeias de Markov via Monte Carlo (MCMC) constituem uma das ferramentas mais poderosas da estatística moderna, permitindo amostrar distribuições complexas e de elevada dimensão. Este relatório apresenta uma análise teórica e prática do Metropolis-Hastings, da Amostragem de Gibbs, abordando o seu funcionamento, diagnóstico de convergência e principais aplicações, o método Hamiltonian Monte Carlo e o método No-U-Turn Sample. Incluímos implementação em R com análise gráfica e discussão sobre otimização da proposta. A análise reforça a importância da avaliação rigorosa da convergência para garantir estimativas fiáveis bem como a aplicabilidade dos métodos MCMC em contextos científicos e tecnológicos diversos.

Index Terms—MCMC, Metropolis-Hastings, Cadeias de Markov, Convergência, Gelman-Rubin, Inferência Bayesiana, Simulação.

I. INTRODUÇÃO

Os métodos de Monte Carlo são amplamente utilizados para resolver problemas cuja resolução analítica é inviável. Entre estes, os métodos MCMC distinguem-se pela capacidade de gerar amostras de distribuições complexas através de cadeias de Markov que convergem para uma distribuição alvo.

Estes métodos revolucionaram a inferência bayesiana e tornaram-se essenciais em áreas como a física estatística, a biologia computacional, a economia e o machine learning. O presente relatório tem como objetivos: (i) descrever o funcionamento e os fundamentos dos métodos MCMC, (ii) apresentar técnicas de monitorização da convergência e (iii) ilustrar uma aplicação prática em linguagem R.

II. FUNDAMENTOS TEÓRICOS

A. Propriedades das Cadeias de Markov

Uma cadeia de Markov é caracterizada pela propriedade de Markov: o estado futuro depende apenas do estado presente, e não dos estados anteriores. A cadeia é definida pelo kernel de transição $K(x, y)$, que representa a probabilidade de transitar do estado x para o estado y . Quando a cadeia é irredutível e aperiódica, garante-se a existência de uma distribuição estacionária π única. Nos métodos MCMC, constrói-se deliberadamente uma cadeia cujo kernel satisfaz a condição de equilíbrio detalhado:

$$\pi(x)K(x, y) = \pi(y)K(y, x).$$

Esta propriedade assegura que π permanece invariante ao longo do tempo, permitindo que as amostras, após convergência, sejam utilizadas para estimar integrais de interesse.

B. Teorema Ergódico e Consistência

O teorema ergódico garante que, para cadeias ergódicas (irredutíveis e aperiódicas), a média amostral converge quase certamente para o valor esperado:

$$\frac{1}{n} \sum_{t=1}^n h(X_t) \approx \mathbb{E}_\pi[h(X)].$$

Este resultado fundamenta a validade das estimativas MCMC: ao contrário dos métodos clássicos que exigem independência, o MCMC permite usar amostras dependentes para estimar integrais desde que a cadeia seja ergódica.

C. Escolha e Ajuste da Proposta

A eficiência dos métodos MCMC depende fortemente das escolhas algorítmicas específicas de cada método. No Metropolis-Hastings, a escolha da distribuição de proposta $q(y | x)$ é determinante. Propostas demasiado estreitas originam forte autocorrelação, enquanto propostas excessivamente amplas reduzem a taxa de aceitação. A taxa ideal situa-se entre 20% e 40%. É comum ajustar a variância da proposta (por exemplo, σ^2 numa proposta Normal) até atingir esse intervalo.

Na Amostragem de Gibbs, por outro lado, não há proposta explícita nem taxa de aceitação — as amostras são geradas diretamente das distribuições condicionais completas. A eficiência depende da correlação entre as variáveis: quanto maior a correlação, mais lenta é a convergência, pois cada atualização fornece menos informação nova sobre o espaço de estados.

D. Comparação entre Métodos

1) Algoritmo de Metropolis-Hastings:

a) **Definição:** O algoritmo de Metropolis-Hastings (MH) permite amostrar de uma densidade alvo $\pi(x)$ construindo uma cadeia de Markov cuja distribuição estacionária é precisamente π . O método gera uma proposta a partir de uma distribuição $q(y | x)$ e decide aceitá-la ou rejeitá-la com base numa probabilidade de aceitação que garante a invariância de π .

Os requisitos práticos são:

- conseguir avaliar $\pi(x)$ à constante de normalização perto (a constante cancela na razão de aceitação);
- escolher $q(\cdot | x)$ com dispersão suficiente para explorar o suporte de π .

Algorithm 1 Metropolis-Hastings (uma iteração)

- Dado o estado atual $x^{(t)}$
- Gerar proposta $y \sim q(\cdot | x^{(t)})$
- Calcular

$$\alpha = \min \left\{ 1, \frac{\pi(y) q(x^{(t)} | y)}{\pi(x^{(t)}) q(y | x^{(t)})} \right\}$$

- Atualizar

$$x^{(t+1)} = \begin{cases} y, & \text{com probabilidade } \alpha, \\ x^{(t)}, & \text{caso contrário.} \end{cases}$$

O MH é o método MCMC mais geral e serve de base a variantes mais eficientes, destacando-se:

- Amostragem de Gibbs:** Algoritmo de Monte Carlo via Cadeias de Markov (MCMC) usado para gerar amostras de uma distribuição conjunta complexa $f(x_1, x_2, \dots, x_p)$, quando é difícil amostrar diretamente dela. A ideia central é amostrar sucessivamente de distribuições condicionais mais simples, até que a sequência de amostras convirja para a distribuição alvo.

b) **Amostragem de Gibbs a Duas Etapas:** A amostragem de Gibbs de duas etapas constrói uma cadeia de Markov a partir de uma distribuição conjunta do seguinte modo:

Suponha que duas variáveis aleatórias X e Y têm uma densidade conjunta $f(x, y)$, com as respetivas densidades condicionais $f_{Y|X}$ e $f_{X|Y}$. A amostragem de Gibbs de duas etapas gera então uma cadeia de Markov (X_t, Y_t) através dos seguintes passos:

Algorithm 2 Amostragem de Gibbs – Duas Etapas

- 1: Escolher um valor inicial $X_0 = x_0$
 - 2: **for** $t = 1, 2, \dots$ **do**
 - 3: Gerar Y_t a partir de $f_{Y|X}(\cdot | X_{t-1})$
 - 4: Gerar X_t a partir de $f_{X|Y}(\cdot | Y_t)$
-

c) *Amostragem de Gibbs de Multietapas*: A amostragem de Gibbs de duas etapas pode ser naturalmente estendida ao Gibbs sampler multietapas. Suponha que, para algum $p > 1$, a variável aleatória $\mathbf{X} = (X_1, \dots, X_p)$ tem densidade conjunta $f(x_1, \dots, x_p)$. Se for possível simular das condicionais completas $f_i(x_i | x_{-i})$, então o algoritmo é:

Algorithm 3 Amostragem de Gibbs – Multietapas

- 1: Dado $\mathbf{x}^{(t)} = (x_1^{(t)}, \dots, x_p^{(t)})$
 - 2: **for** $i = 1, \dots, p$ **do**
 - 3: Gerar $X_i^{(t+1)} \sim f_i(x_i | x_1^{(t+1)}, \dots, x_{i-1}^{(t+1)}, x_{i+1}^{(t)}, \dots, x_p^{(t)})$
-

- **Hamiltonian Monte Carlo (HMC)**: Introduce uma variável de *momento* p e define-se a energia potencial $U(\theta) = -\log \pi(\theta)$ e a energia cinética $K(p) = \frac{1}{2}p^\top M^{-1}p$, com matriz de massa $M \succ 0$. O Hamiltoniano é:

$$H(\theta, p) = U(\theta) + K(p).$$

O integrador *leapfrog* propõe saltos longos com alta probabilidade de aceitação, reduzindo a autocorrelação e aumentando o ESS.

Algorithm 4 HMC (uma iteração, leapfrog com L passos e passo ε)

- 1: Estado atual $\theta^{(t)}$
 - 2: Amostrar $p \sim \mathcal{N}(0, M)$
 - 3: $(\theta', p') \leftarrow (\theta^{(t)}, p)$
 - 4: **for** $\ell = 1, \dots, L$ **do**
 - 5: $p' \leftarrow p' - \frac{\varepsilon}{2} \nabla U(\theta')$
 - 6: $\theta' \leftarrow \theta' + \varepsilon M^{-1} p'$
 - 7: $p' \leftarrow p' - \frac{\varepsilon}{2} \nabla U(\theta')$
 - 8: Definir $p' \leftarrow -p'$
 - 9: Calcular $\alpha = \min\{1, \exp[H(\theta^{(t)}, p) - H(\theta', p')]\}$
 - 10: Aceitar (θ', p') com probabilidade α
-

- **No-U-Turn Sampler (NUTS)**: Extensão do HMC que adapta automaticamente o comprimento da trajetória, interrompendo-a quando detecta que o movimento está prestes a inverter a direção (*no U-turn*). Evita a calibração manual do número de passos de integração, tornando o método mais eficiente em espaços de alta dimensão. Está implementado em pacotes modernos como Stan e PyMC.

III. MONITORIZAÇÃO DA CONVERGÊNCIA

Implementou-se o algoritmo de Metropolis-Hastings para a densidade:

$$\pi(x) \propto e^{-x^4 + x^2 - x}, \quad x \in \mathbb{R}.$$

Foram geradas duas cadeias de 10 000 iterações com $\sigma = 1$. A convergência deve ser avaliada tanto de forma visual como estatística. Os traceplots e a função de autocorrelação (ACF) permitem avaliar a mistura da cadeia, enquanto a estatística $\hat{R}$ mede a variabilidade entre cadeias independentes.

A. Traceplots, Autocorrelação e Gelman-Rubin




Figura 1. Traceplots das duas cadeias MH.

Os traceplots mostram a trajetória das duas cadeias ao longo de 10.000 iterações. Ambas estabilizam rapidamente em torno da mesma região do espaço amostral, indicando que a convergência para o regime estacionário ocorre por volta das 2.000 iterações. As flutuações aleatórias em torno de uma média constante sugerem uma boa mistura das cadeias e uma ausência de aprisionamento local, enquanto a variabilidade entre iterações evidencia uma exploração eficiente do espaço de estados.




Figura 2. Função de autocorrelação (ACF) das amostras.

A ACF apresenta uma descida acentuada nas primeiras defasagens (lags), aproximando-se de zero a partir de $lag \approx 10$. Isto indica que a dependência entre amostras consecutivas é reduzida, assegurando um tamanho efetivo da amostra (ESS) adequado. Caso a ACF decaísse lentamente, tal refletiria mistura deficiente e necessidade de ajustar a proposta — o que não se verifica neste caso.




Figura 3. Estatística $\hat{R}$ de Gelman-Rubin.

A estatística de Gelman-Rubin avalia a consistência entre cadeias independentes. Com $\hat{R} = 1.01$, observa-se que as variâncias intra e intercadeias são praticamente idênticas, demonstrando convergência global. Valores superiores a 1.1 indicariam discrepâncias significativas entre cadeias — o que não ocorre. O valor obtido confirma a estabilidade do algoritmo e a ausência de enviesamentos sistemáticos.

IV. IMPLEMENTAÇÃO DO ALGORITMO EM R

Nesta secção considerou-se apenas uma das cadeias geradas, de modo a facilitar a interpretação dos resultados e evitar a duplicação de amostras correlacionadas. O objetivo é ilustrar o comportamento do algoritmo de Metropolis–Hastings aplicado à função alvo previamente definida, destacando os principais aspetos da sua implementação e análise numérica.




Figura 4. Histograma das amostras e densidade alvo teórica.

O histograma sobrepõe-se à densidade alvo (linha vermelha) de forma notavelmente próxima. Observa-se a assimetria esperada, com maior concentração de probabilidade à esquerda e cauda mais longa à direita. As pequenas discrepâncias nas extremidades refletem a menor frequência de amostras em regiões de baixa densidade, comportamento típico de cadeias MH. O resultado comprova que o método recupera com elevada fidelidade a forma da densidade alvo, mesmo sem conhecer a sua constante de normalização.




Figura 5. Taxa de aceitação ao longo das iterações.

A taxa de aceitação estabiliza em torno de aproximadamente 55%, valor ligeiramente acima do intervalo ideal (20–40%). Isto indica que a proposta utilizada é algo conservadora, produzindo saltos curtos e uma taxa elevada de aceitações. Apesar disso, a estabilidade observada ao longo das iterações demonstra que a cadeia atingiu o regime estacionário e que o processo de amostragem é fiável, assegurando estimativas consistentes.




Figura 6. QQ-Plot: comparação entre quantis teóricos e amostrais.

A proximidade dos pontos à diagonal confirma que a distribuição empírica obtida pelas amostras MCMC coincide com a forma teórica esperada. As ligeiras divergências nas caudas são irrelevantes e associadas à variabilidade inerente ao método de Monte Carlo. Este gráfico reforça que a cadeia explora corretamente todo o suporte da distribuição, sem enviesamentos significativos.




Figura 7. Evolução da média acumulada das cadeias.

A média acumulada $\hat{\mu}_t = \frac{1}{t} \sum_{i=1}^t X_i$ estabiliza após cerca de 2000 iterações, confirmando empiricamente o teorema ergódico. O valor final converge para $E[X] \approx -0.476$, consistente com as estimativas numéricas obtidas. A linha vermelha assinala o valor médio final, evidenciando estabilidade e ausência de tendência direcional.

V. RESULTADOS NUMÉRICOS E DISCUSSÃO

O valor médio estimado de $E[X]$ foi -0.476 , com desvio-padrão 0.636 . O tamanho efetivo da amostra (ESS) foi de 1641 , indicando que cerca de 16% das iterações são efetivamente independentes. Apesar de moderado, este valor é suficiente para estimativas estáveis. O tempo total de execução foi inferior a 2 segundos.

A relação $ESS/N = 0.16$ mostra dependência temporal moderada, mas aceitável. Um ligeiro ajuste em σ (por exemplo, 0.9) poderia aumentar a eficiência. O valor médio negativo reflete a assimetria da densidade, com maior massa de probabilidade para $x < 0$. O desvio-padrão moderado e a estabilidade das médias acumuladas reforçam a robustez da amostragem.

VI. APLICAÇÕES E CONCLUSÕES

O algoritmo de Metropolis-Hastings demonstrou ser capaz de reproduzir distribuições complexas de forma eficiente. As aplicações práticas dos métodos MCMC incluem:

- **Inferência Bayesiana:** estimação em modelos hierárquicos e regressões não lineares;
- **Física Computacional:** simulação de sistemas moleculares e estudo de estados de equilíbrio;
- **Aprendizagem Automática:** inferência em modelos probabilísticos complexos;
- **Finanças e Epidemiologia:** previsão de volatilidade e modelação de contágio.

A eficiência dos métodos MCMC depende fortemente do ajuste da proposta e da análise rigorosa da convergência. Como trabalho futuro, propõe-se comparar variantes como o HMC e o NUTS, avaliando ganhos em ESS sem comprometer a precisão.

VII. EXTENSÕES E AVALIAÇÃO DE DESEMPENHO

Para complementar a análise, avaliou-se a suavidade e cobertura da amostragem através da densidade kernel estimada a partir das amostras MCMC. A Figura 8 apresenta a comparação entre a densidade empírica e a teórica.




Figura 8. Densidade kernel estimada vs densidade teórica.

Observa-se excelente concordância, demonstrando que o método explora adequadamente todo o suporte da distribuição. A pequena discrepância nas caudas é explicada pela baixa frequência de amostras extremas, fenómeno típico em distribuições com caudas finas.

Comparando com a Amostragem de Gibbs, o algoritmo de Metropolis-Hastings apresenta maior flexibilidade, pois permite usar propostas arbitrárias. No entanto, o Gibbs tende a convergir mais rapidamente em situações com condicionais analíticas conhecidas.

Em contrapartida, o MH é aplicável em contextos onde apenas se conhece a densidade até uma constante de normalização.

Para melhorar o desempenho, pode recorrer-se a versões adaptativas (*Adaptive Metropolis*), em que a variância da proposta é ajustada com base na covariância das amostras passadas. Esta abordagem reduz a necessidade de calibração manual e melhora o ESS em distribuições multidimensionais.

Outra possibilidade é utilizar o *Delayed Rejection Adaptive Metropolis* (DRAM), que combina rejeições sucessivas com adaptação progressiva, aumentando a eficiência sem comprometer a ergodicidade da cadeia.

A. Limitações e Robustez Numérica

Apesar da eficácia observada, os métodos MCMC apresentam desafios práticos. A escolha inadequada da distribuição de proposta pode originar tempos de convergência prolongados, e a dependência serial entre amostras reduz a informação efetiva disponível. Em contextos de elevada dimensionalidade, a avaliação da convergência torna-se mais complexa, exigindo a utilização combinada de vários diagnósticos.

Ainda assim, os resultados obtidos demonstram que, mesmo com um tamanho efetivo da amostra moderado ($ESS = 1641$), as estimativas são consistentes e estáveis. Este facto reforça a robustez do método e a validade dos resultados alcançados, sobretudo quando a convergência é monitorizada de forma sistemática.

B. Perspetivas Futuras e Impacto Prático

Os métodos MCMC continuam a evoluir rapidamente, impulsionados pelos avanços na computação paralela e na utilização de algoritmos de otimização estocástica. Em particular, o surgimento de variantes baseadas em gradientes, como o *Stochastic Gradient Langevin Dynamics* (SGLD) e o *Hamiltonian Variational Inference*, tem permitido aplicar MCMC a grandes volumes de dados, mantendo as propriedades assintóticas de correção estatística.

O impacto destes métodos é notório em áreas como a modelação de redes neuronais bayesianas, a calibração de modelos climáticos e a inferência em epidemiologia dinâmica. Nestes contextos, o MCMC assume-se não apenas como uma ferramenta de amostragem, mas como uma ponte entre a estatística teórica e a modelação de sistemas complexos do mundo real.

No futuro, espera-se que a combinação de MCMC com técnicas de *machine learning* — nomeadamente através do uso de redes neuronais para definir propostas inteligentes (*learned proposals*) — torne o processo mais adaptativo e eficiente, reduzindo significativamente os tempos de convergência e aumentando a escalabilidade em múltiplas dimensões.

C. Conclusão Geral

Em síntese, o estudo desenvolvido demonstra que, mesmo em modelos unidimensionais simples, o MCMC requer uma análise cuidadosa da convergência e da eficiência amostral. A aplicação prática em R comprovou que uma implementação devidamente calibrada é capaz de produzir resultados precisos e interpretáveis. Com a integração de técnicas adaptativas e o recurso a diagnósticos rigorosos, o MCMC continuará a constituir um dos pilares centrais da estatística computacional moderna e uma das ferramentas mais versáteis ao dispor do cientista de dados.

REFERÊNCIAS

- [1] S. Brooks, A. Gelman, G. Jones e X.-L. Meng, *Handbook of Markov Chain Monte Carlo*, CRC Press, 2011.
- [2] A. Gelman e D. Rubin, "Inference from iterative simulation using multiple sequences," *Statistical Science*, vol. 7, n.º 4, pp. 457–472, 1992.
- [3] M. Plummer, N. Best, K. Cowles e K. Vines, "CODA: Convergence diagnosis and output analysis for MCMC," *R News*, vol. 6, n.º 1, pp. 7–11, 2006.
- [4] R. Neal, "MCMC using Hamiltonian dynamics," in *Handbook of Markov Chain Monte Carlo*, CRC Press, 2011.
- [5] C. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [6] A. Gelman et al., *Bayesian Data Analysis*, 3rd ed., CRC Press, 2013.